



## INF-317B - Tópicos em Inteligência Artificial: Machine Learning

**Professores:** André Kazuo Takahata e Ricardo Suyama

**Quadrimestre:** 2020.1

**Data:** 19/03/2020

**Entrega pelo TIDIA4:** 02/04/2020

### Exercícios Individuais para Envio pelo TIDIA4

#### Instruções

- 1) Para as questões abaixo considere como  $d_4d_3d_2d_1$  os 4 últimos dígitos menos significativos de seu RA. Por exemplo, se o RA=2120201567 então  $d_4=1$ ,  $d_3=5$ ,  $d_2=6$  e  $d_1=7$ . Caso não possua RA então utilize 4 números gerados aleatoriamente (utilize os mesmos números no decorrer da lista).
- 2) Fazer as questões **à mão**, com exceção daquelas marcadas com “**(Computador)**”, e enviar a resolução escaneada. Caso contrário elas **não serão consideradas**.
- 3) Os exercícios são **individuais**. Questões com plágio ou exercícios em duplas **não serão aceitos**.

#### Questões

- 1) Considere que uma loja está fazendo uma promoção com o uso da roleta mostrada na Figura 1. A roleta é dividida em 8 setores circulares iguais e a cada setor é associada a um desconto. Na promoção, ao realizar uma compra, o cliente gira a seta e ganha o desconto correspondente ao setor que a seta aponta quando cessa o movimento. Caso a seta aponte para o setor marcado com a interrogação, o cliente ganha  $d_1\%$  de desconto.
  - a. Seja  $X$  uma variável aleatória que representa o desconto que um cliente irá obter em uma compra de R\$100,00 e  $\theta$  o ângulo entre a seta e a vertical conforme mostrado na Figura 1. Dê a descrição de  $X$  em função de  $\theta$ .
  - b. Considere que a seta para em qualquer ângulo  $\theta$  com a mesma probabilidade. Dê a PMF de  $X$ .

- c. Quais são os valores de  $E[X]$  e  $\text{var}(X)$ ?




Figura 1: Roleta utilizada na Questão 1.

- 2) Considere o problema de classificação unidimensional com duas classes em que:

$$p(x|\omega_1) \sim \mathcal{N}(d1,1)$$

$$p(x|\omega_2) \sim \mathcal{N}(d1 + 2,1)$$

$$\Pr(\omega_1) = \Pr(\omega_2) = 1/2$$

- (Computador)** Trace os gráficos de  $p(x|\omega_i)$  e  $p(x) \cdot p(x|\omega_i)$  para ambas classes
- Obtenha a regra de decisão ótima analiticamente e com o uso do gráfico obtido no item a)
- (Computador)** Simule a classificação de  $N = 1000$  objetos. Qual é o erro de classificação obtido?

- 3) Considere o problema de classificação unidimensional com duas classes em que:

$$p(x|\omega_1) \sim \mathcal{N}(d2,1)$$

$$p(x|\omega_2) \sim \mathcal{N}(d2,4)$$

$$\Pr(\omega_1) = \Pr(\omega_2) = 1/2$$

- (Computador)** Trace os gráficos de  $p(x|\omega_i)$  e  $p(x) \cdot p(x|\omega_i)$  para ambas classes

- b. Obtenha a regra de decisão ótima analiticamente e com o uso do gráfico obtido no item a)
- c. **(Computador)** Simule a classificação de  $N = 1000$  objetos. Qual é o erro de classificação obtido?

4) Considere o problema de classificação unidimensional com duas classes em que  $x$  é uma grandeza obtida por meio de um exame e  $\omega_1$  e  $\omega_2$  representam, respectivamente, pacientes saudáveis e doentes tal que:

$$p(x|\omega_1) \sim \mathcal{N}(d2,1)$$

$$p(x|\omega_2) \sim \mathcal{N}(d2 + 3,1)$$

$$\Pr(\omega_1) = 0,99$$

$$\Pr(\omega_2) = 0,01.$$

- a. Obtenha a regra de decisão ótima considerando que os falsos positivos e os falsos negativos possuem o mesmo erro.
- b. **(Computador)** Simule a classificação de  $N = 10000$  pacientes. Preencha a tabela de contingência abaixo e dê os valores de verdadeiros positivos (TP), verdadeiros negativos (TN), falsos positivos (FP) e falsos negativos (FN). Também dê a acurácia, a sensibilidade e a especificidade do teste.

	Classe verdadeira	
	$\omega_1(-)$	$\omega_2(+)$
Resultado +		
Resultado -		

- c. Desenhe um diagrama de Venn ilustrando as informações obtidas no Item b).
- d. Caso um paciente receba resultado positivo, qual é a probabilidade de ele estar realmente doente?
- e. Caso um paciente receba um resultado negativo, qual é a probabilidade de ele estar realmente saudável?
- f. Refaça os itens a) a d) admitindo que a perda associada ao falso negativo é 100 vezes pior que a perda associada ao falso positivo.

- 5) Considere o problema de classificação bidimensional em que o vetor de características é tal que  $\mathbf{x} = [x_1, x_2]^T$  e as classes são representadas por  $\omega_1$  e  $\omega_2$ .

- a. Obtenha a fronteira de decisão ótima para

$$p(\mathbf{x}|\omega_1) \sim \mathcal{N}(\boldsymbol{\mu}_1, \mathbf{I})$$

$$p(\mathbf{x}|\omega_2) \sim \mathcal{N}(\boldsymbol{\mu}_2, \mathbf{I})$$

$$P(\omega_1) = P(\omega_2) = 1/2$$

em que  $\boldsymbol{\mu}_1 = [d1, d2]^T$  e  $\boldsymbol{\mu}_2 = [d3, d4]^T$ .

- b. Repita o item a. modificando as probabilidades *a priori* para  $P(\omega_1) = 1/3$  e  $P(\omega_2) = 2/3$ .
- c. Repita o item a. agora alterando a matriz de covariância de modo que as variâncias de  $x_1$  e  $x_2$  sejam diferentes e haja correlação entre  $x_1$  e  $x_2$ . Qual é o valor da correlação no caso? A matriz de covariância deve ser igual para ambas classes.
- d. **(Computador)** Para os Itens a. a d., simule a classificação de  $N = 1000$  objetos. Faça um gráfico mostrando os dados gerados e a fronteira de decisão para cada caso. Qual é o erro de classificação obtido?
- e. **(Computador)** Utilize o classificador obtido em a. para os dados gerados nos Itens b. e c. O que ocorre com o erro de classificação?

- 6) Considere o problema de classificação bidimensional em que o vetor de características é tal que  $\mathbf{x} = [x_1, x_2]^T$  e as classes são representadas por  $\omega_1$  e  $\omega_2$ .

- a. Obtenha a fronteira de decisão ótima para

$$p(\mathbf{x}|\omega_1) \sim \mathcal{N}(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1)$$

$$p(\mathbf{x}|\omega_2) \sim \mathcal{N}(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}_2)$$

$$P(\omega_1) = P(\omega_2) = 1/2$$

em que

$$\boldsymbol{\mu}_1 = [0,0]^T, \boldsymbol{\mu}_2 = [0,4]^T,$$

$$\boldsymbol{\Sigma}_1 = \begin{bmatrix} 20 + d1 & 0 \\ 0 & 1 \end{bmatrix} \text{ e } \boldsymbol{\Sigma}_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

Para isso obtenha os pontos  $[x_1, x_2]^T$  que satisfaçam a

$$\mathbf{x}^T \mathbf{W}_1 \mathbf{x} + \mathbf{w}_1^T \mathbf{x} + w_{1,0} = \mathbf{x}^T \mathbf{W}_2 \mathbf{x} + \mathbf{w}_2^T \mathbf{x} + w_{2,0}$$

em que

$$\mathbf{W}_i = -\frac{1}{2} \boldsymbol{\Sigma}_i^{-1}, \mathbf{w}_i = \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i$$

$$w_{i0} = -\frac{1}{2} \boldsymbol{\mu}_i^T \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i)$$

para  $i = 1, 2$ .

- b. **(Computador)** Simule a classificação de  $N = 2000$  objetos. Faça um gráfico mostrando os dados gerados e a fronteira de decisão. Qual é o erro de classificação obtido?
- c. **(Computador)** Para o mesmo conjunto de dados utilizado no Item b., obtenha o erro de classificação para o classificador de mínima distância. Compare o desempenho obtido com o do classificador utilizado no Item b.

7) **(Computador)** Escolha o classificador mais adequado entre análise de discriminante linear (LDA) ou quadrática (QDA) para cada situação apresentada nos arquivos dataset1.txt a dataset6.txt e faça testes com uso de validação cruzada no classificador escolhido. Não é necessário calcular a fronteira de decisão explicitamente (mas pode ser feito caso ache necessário).

8) **(Computador)** Considere o arquivo dataset2.txt e o uso do LDA para classificação. Faça a validação cruzada com a subamostragem aleatória com 10 repetições considerando:

- a. Caso 1: 5 vetores para treinamento
- b. Caso 2: 20 vetores para treinamento

Faça um gráfico para cada caso sobrepondo as fronteiras de decisão obtidas em cada repetição da subamostragem aleatória. Qual é a mudança de comportamento observada?

**Dica:** O comando `mvnrnd` do OCTAVE/MATLAB gera valores aleatórios segundo uma distribuição normal multivariada com vetor de média e matriz de covariância arbitrários.